ПРУФ-ИТ / PROOFIT

Всесторонняя валидация

Текущие измерения. Независимые исполнимые оракулы. Ни одного LLM-вызова в протоколе.

Редакция документа: 11 октября 2026. Архитектурные утверждения связаны с указанными модулями; числовые результаты — с протоколами измерений, их датами и областью применимости. Обновление документа не означает повторного проведения всех экспериментов.

Роли: специалист, работодатель, явно одобренный эксперт. Окончательное решение о найме, трактовка спорного evidence и разрешение на обработку данных не передаются автономному score.

1. Итог и доказательная граница

Основная выдача работодателю: Precision@5 100.00%; nDCG@5 98.15% на 494 запросах. Это измерение реального Rust HTTP API на контролируемом dataset, а не прогноз, пересказ или оценка генеративной модели. Доступность и correctness подтверждаются отдельными тестами.

Проверка включает 275 CPU-тестов, 56 live HTTP-тестов, 18 Rust-тестов, OpenAPI, release/web build, реальные sandbox executions и Chromium UI. Один Rust-тест с генеративной зависимостью явно ignored; он не включен в число пройденных. Human cohort и массовая нагрузка не симулируются под названием реального пилота.

2. Протокол и условия

Validation/reports/current содержит только текущий набор наблюдений. Все тесты запускаются на отдельных exact-ID синтетических субъектах с cleanup. HTTP uses настоящие Rust/PG/Keycloak/Docker компоненты; state fixtures задают предварительное состояние и не подставляют HTTP-результат. Native document worker при проверке загрузок приостановлен, чтобы очередь PDF не запустила LLM.

Локальный прогон auth использует реальную identity-службу с отдельными test proxy IP и неизмененными квотами; финальный HTTPS-прогон проходит публичный gateway с настоящими Secure cookies. Это проверяет и изолированный account throttle, и опубликованный browser/API origin. Настоящий Keycloak проверен браузерным authorization-code flow, а не mock redirect.

Среда bounded run: Windows-10-10.0.19045-SP0; Intel64 Family 6 Model 158 Stepping 9, GenuineIntel; 8 logical CPU; 31.9 GiB RAM. Генератор и сервис находятся на одной машине. Результат относится к этому стенду и измеренному workload, не к неизвестной инфраструктуре.

3. Матрица фактических результатов

Проверка	Результат	Интерпретация
CPU unit/property	275 tests; 0 failures/errors	Math, contracts, privacy and lifecycle; не human validation
Native HTTP	56 tests; 0 failures/errors	Реальные сервисы; transient fixtures, genuine Keycloak
Rust / contract	18 passed; 1 ignored; 169 OpenAPI operations	Ignored LLM-test не выдается за passed
Executable role keys	720 cases; 2700 parameterized form checks	Python, SQLite, Node; zero generated answer keys
Browser	8 checks; 0 JS errors	Базовый UI-срез до изменения авторизации; новый UI проверен отдельно
Employer retrieval	P@5 100.00%; nDCG@5 98.15%	494 scenario vacancies; separate gold; real API
Candidate discovery	nDCG@5 91.48%; Recall@10 93.05%	66 role/grade queries; transposed gold
Antiplag copy signals	120/120 transformations detected	Controlled positive corpus; no automatic sanctions
CAT conditional classification	96.20% at 65.83% certainty coverage	Monte Carlo under authored response process
Bounded HTTP	4039 requests; 0 errors; 130.01 req/s	30 sessions, 30s paced closed loop, local transport

4. Поиск работодателя: качество ранней выдачи

Срез содержит 4040 профилей и 494 вакансии, 1 995 760 размеченных пар. Релевантность 0–3 хранится вне API и не передается обработчику. P@5=100.00%; nDCG@5=98.15%; MRR@10=100.00%; MAP@10=97.65%. Bootstrap 95% интервал nDCG@5: 97.11%–98.96%.

Bootstrap: 1000 query-level IID resamples, seed 20261009, macro means. Общие кандидаты между запросами могут создавать зависимость, которая не учтена простым IID interval. Exact top-5 agreement=96.76%; альтернативный порядок проверяется nDCG, а не скрывается изменением gold.

Recall@5=7.54% и Recall@10=14.74% относятся ко всем релевантным объектам большого пула. Для короткой выдачи recall не обязан быть близок к единице; он оценивает полноту, тогда как precision и nDCG — качество первых результатов. Синтетическая разметка подтверждает соответствие заданным профессиональным правилам, не всей реальной экономике найма.

5. Кандидатская рекомендация и условия

Для 66 роль/грейд профилей: Precision@5=88.79%; nDCG@5=91.48%; nDCG@10=94.63%; Recall@10=93.05%. Gold transposed из пар employer-side; directional preferences отличаются и потому представлены отдельно.

Доля top-5 с salary_to≥ожидания: 82.42%. Discovery может показывать варианты с явно объясненным mismatch, тогда как evidence-lab allocation соблюдает hard salary constraint. Данные о зарплатном условии не скрыты и не объявлены равнозначными eligibility. Требования пользователя и работодателя остаются видимыми.

6. Исполнимые оракулы и CAT

Python/SQL/TypeScript answer keys проверены реальным выполнением: по 240 cases каждого языка. 2700 seeded form checks проверяют контракты вариантов, ключи и устойчивость шаблонов. Для quality/operations/leadership структурные задания используют авторскую экспертную постановку; software execution oracle не объявляется независимой человеческой экспертизой.

CAT: 360 trajectories, seed 20261010; correlation θ=0.9657; RMSE θ=0.4172; exact grade=89.44%; within one grade=100.00%. При certainty≥0.85: accuracy=96.20%, coverage=65.83% (237 cases), Wilson95 92.94%–97.99%.

Средняя длина 28.88 scored вопросов, диапазон [24, 32]. Это тест authored 3PL response process без человеческих labels. Высокая simulated accuracy не используется как утверждение о готовой психометрической валидности реального junior/middle/senior.

7. Антиплагиат и global allocation

120 copy transformations: rename, комментарии/пробелы, padding до 39 дополнительных функций. Все 120 обнаружены; sensitivity Wilson95 96.90%–100%. Три отдельно написанных реализации той же задачи дали 0 false alerts; столь малый negative corpus не позволяет назвать open-world precision равной 100%.

Starter code вычитается, несовместимые task/language/version не сравниваются, automatic penalties=0. Independent approved review и право challenge проверены HTTP. Для allocation 20 random small instances сопоставлены с exhaustive enumeration, включая dummy assignment, forbidden pair и несколько резюме одного человека. Точный optimum доказан в проверенных bounded instances относительно заявленной utility.

8. Forecast holdout и сценарная устойчивость

Замороженные CatBoost модели проверены на 3000 новых generator rows каждая, seed 20261009, без retune на holdout. Vacancy fill: R^2=0.932733, MAE=0.9017 дня. Candidate search: R^2=0.990549, MAE=0.8551 дня.

В 100 проверенных контрфактуалах каждого направления ухудшений=0/0. Target reduction достигнут в 50/98 cases; mean reduction 1.01/7.86 дня. Это generator-domain accuracy и model scenario consistency, не реальное сокращение сроков найма у работодателей.

9. Ограниченное эксплуатационное испытание

30 отдельных authenticated sessions, 30 секунд, synchronized start, paced closed-loop с потолком 5 req/s/session (150 req/s offered). Workload: dashboards, candidate search / vacancy list, notifications, CPU catalog. Сохраняются реальные shared-IP perimeter limits. OCR, generative review, upload processing и удаленная сеть не включены.

Фактически 4039 запросов за 31.0661 с; throughput 130.01 req/s; ошибок 0; median 7.015 ms; P95 395.926 ms; P99 674.969 ms. Целевой rate задан, поэтому это проверка устойчивости workload, не

поиск максимального throughput и не capacity extrapolation.

Независимый latency-profile: 150 последовательных операций на 10 endpoints; median 4.9312 ms; P95 162.6525 ms; errors 0. CPU module latency не называется HTTP latency; first request и warmed samples в report отделены.

10. Traceability и воспроизведение

Файлы JSON/XML/screenshots — machine evidence, не параллельная prose-документация. Проверочные команды и scope перечислены в 08_Operations_and_API.pdf. validation/reports/current/source-manifest.json фиксирует SHA-256 текущих исходников, frozen artifacts и contract. Generated PDF inspection проверяет извлечение текста, ссылки, страницы, отсутствие устаревших документов и forbidden editorial content.

Протокол намеренно оставляет границы результата видимыми: synthetic ≠ human; generator holdout ≠ observed hires; authored parameters ≠ psychometric calibration; static Helm validation ≠ deployed cluster; local latency ≠ WAN latency. Это делает сильные фактические значения пригодными для технической проверки, а не рекламной подмены.

11. Проспективный ledger и проверяемая вероятность

Владелец вакансии выбирает существующего участника процесса и фиксирует прогноз до первого явно выраженного намерения каждой стороны. Rust самостоятельно вычисляет вероятность из завершённых предыдущих пар, сохраняет роль, грейд, стадию, model version и серверное время. Клиент не задаёт вероятность или исход. В реальной вакансии синтетические участники не входят в обучающий счётчик. Advisory-lock сериализует запись прогноза и намерений для одной пары/стадии; clock_timestamp фиксирует фактическое время после получения блокировки.

Записи prospective_predictions неизменяемы на уровне PostgreSQL trigger. Когда обе стороны ответили после снимка, отдельно однократно сохраняется первый парный исход в prospective_outcomes. Позднейшее изменение намерения не меняет исход оценки. Отчёт считает Brier=$(p-y)^2$, log loss, ECE по десяти фиксированным интервалам и AUC с корректными ties. Одноклассовой выборке AUC не присваивается. Joint point оценивается лишь для снимков с идентифицированной совместной оценкой; coverage показано отдельно. Vacancy/offer и role/grade blocks не смешиваются.

Синтетические записи исключаются, неполные пары считаются цензурированными. Минимум для диагностической достаточности — 120 завершённых пар и 20 наблюдений каждого класса; количество не даёт автоматического допуска к калибровке. Зависимость повторных кандидатов и вакансий сохраняется; отчёт не приписывает этим записям независимый популяционный confidence interval. Online report ограничен 500 снимками, owned export — 5000; превышение явно требует фильтра vacancy/stage или отдельного протокола, а не тихо усекает данные. Намерение не означает трудоустройство.

12. Измерения завершённого программного контура

Прицельные CPU/HTTP/browser протоколы проверяют изменённые компоненты. Старые workload, forecasting и retrieval измерения не перезапускались и сохраняют собственную дату. Ни одно число ниже не названо реальным эффектом найма.

Контроль	Результат	Знаменатель
Proper scoring oracle |ΔBrier|	0.0	2000 controlled predictions
Proper scoring oracle |ΔLogLoss|	0.0	2000 controlled predictions
Future-label leakage rejection	120/120	Преднамеренно нарушенная хронология
Paired TOST positive control	True	200 controlled paired observations
Shift +0,5 negative control	True	200 controlled paired observations
Macro paired-loss oracle |Δ|	2.78e-17	160 controlled rows / 40 dates
CPU report P95	2.665 ms	120 records; 5 warm-up + 40 timed runs
Static locale coverage	1544/1544 × 5	EN/KK/UZ/AZ/BE; 0 structural errors

13. Прицельная верификация завершённого контура

CPU-срез включает новую prospective/economic логику и затронутые research methods. HTTP проверяет immutable ledger, первый парный outcome, ownership/export, stage filtering, четыре concurrent freeze, фактический response timestamp и тренировку с новыми параметрами. Node проверяет admission и отказ при stale source/catalog hash; Chromium — шесть языков в двух кабинетах. Повторные запуски не складываются с историческими suites; прицельный срез не называется новой полной перепроверкой всей платформы.

Область прицельного среза	Уникальных тестов / сценариев	Результат
CPU methods	113	0 failures / 0 errors
Rust/PG HTTP	10	0 failures / 0 errors
Build-time locale integrity	5	0 failures / 0 errors
Six-language cabinets	12	0 JavaScript errors / 0 overflow

14. Воспроизводимые измерения расширения

Контроль выполняется без LLM, с фиксированным seed и сохранёнными JSON/XML протоколами. Числа характеризуют определённые процессы и выборки, а не все реальные случаи найма.

Метрика	Измерение	Область
Hash allocation A share	50.47% / n=10 000	Контролируемые идентичности, один блок
90% interval coverage	90.68% / n=5 000	Binomial n=120; simulated truths
Fréchet violations	0	5 000 независимых численных случаев
GNN permutation max |Δ|	1.67e-16	100 графов / 2 000 узлов
GNN complete inference P95	1.088 ms	Подготовка tensors + inference; графы по 20 узлов
GNN teacher MAE	0.002942	80 seed-disjoint контрольных графов
TOST controlled p	6.9e-09	По 1 000 наблюдений, не human equating
Shifted control rejected	True	Заданный сдвиг +0,5
Real GitHub public read	1 файлов / 1 коммит / 4 вопроса	Реальный REST, без вывода об авторстве

15. Проверка исполнимого контура

Наборы тестов перечислены отдельно без повторного суммирования перезапусков. Проверена фактическая выдача role-reviewed после независимого review, отказ обычному работодателю, скрытые ответы, CAS, ownership, общий cohort и stage separation. Сквозной GitHub сценарий использует реальное чтение публичного PR и одноразовые синтетические identity/score fixtures; не имитирует аттестацию реального автора.

Протокол	Тестов	Результат
CPU и security HTTP	341	0 failures / 0 errors
Регрессионные HTTP	36	0 failures / 0 errors
Сквозные public contribution HTTP	6	0 failures / 0 errors

16. Ограниченная нагрузка новых методов

Своя нагрузочная выборка: 8 авторизованных сессий, 400 запросов, 0 ошибок; P95=33.21 ms, P99=46.43 ms, throughput=39.63 req/s. Десять секунд, потолок 40 req/s, warm-up, реальные Rust gateway/PostgreSQL/numerical engine. Проверены workspace, role matrix, graph, market, reliability и bilateral. Нет внешних API, OCR, Docker-задач или LLM в workload. Числа не экстраполируются на миллионы сессий.

17. Проверка изменений представления

В этой редакции повторены только затронутые численные и UI-инварианты: 301 CPU-проверка методов, 3 новые проверки полноты предпосылок и приватного управления графом, 5 Node-проверок навигации и точной provenance-проекции. Browser protocol — decision-workspace-ui.json. Синтетический source fixture проверяет связь интерфейса с артефактом; он не является независимой аттестацией реального специалиста. Старые workload и retrieval benchmark не перезапускались и сохраняют дату измерения.

18. Прицельный срез обновленного интерфейса

Retrieval и forecasting отчеты сохраняют собственную дату и область. Ограниченная нагрузка штатных маршрутов повторена после расширения; новые методы имеют отдельный bounded research workload. Изменённые методы проверены research-all-cpu/research-regression-http/research-http протоколами; математические controls приведены в 12_Contribution_and_Decision_Science.pdf. Auth revision проверен отдельным Chromium-протоколом с принудительной pause-recovery; 11_Interface_and_Demo.pdf содержит identity-flow и расширенные UI-сценарии. Протоколы разных областей не складываются как независимые рыночные наблюдения.

19. Восстановление и внешний identity-flow

Рабочая БД не перезаписывалась: backup восстановлен в новую изолированную БД. Для 18 таблиц совпали число строк и digest полного содержимого; 88 файлов storage проверены SHA-256. Проверочная БД после испытания удалена; исходный backup сохранен в ignored runtime. Identity DB Keycloak имеет отдельный lifecycle и не выдается за часть этого application restore.

После переключения HTTPS-origin дополнительно проверяются public SPA, bearer/session ownership, фактическая PKCE/JWKS авторизация и графовый review lifecycle. Повторные native проверки не прибавляются к числу уникальных тестов. Public и local transport явно разделены; bounded benchmark остается локальным.

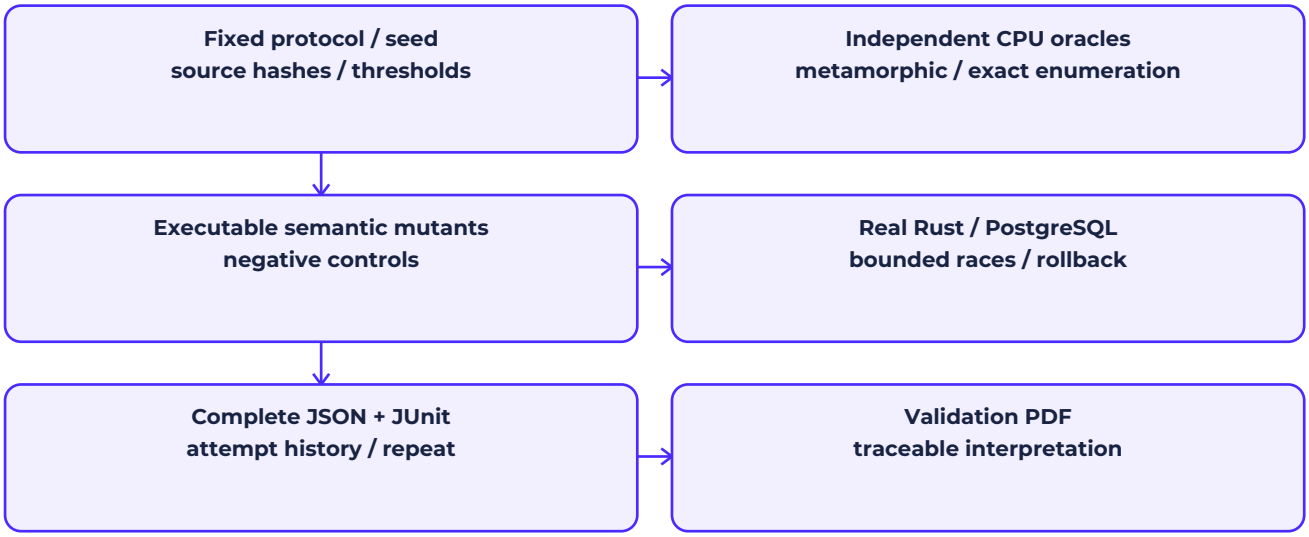
20. Идентификатор текущего инженерного среза

SHA-256 агрегированного manifest исходников, моделей и контрактов: `b0afd9ae15dbef322f30f438e25872f595b8ab07e13885f25586767fda40a59d`. Полный список файлов — validation/reports/current/source-manifest.json. Базовая сборка — build.json; измененная сборка интерфейса/демо, если имеется, — interface-revision-build.json. Manifest характеризует текущие исходники, а каждый протокол — собственную область и дату измерений. Это позволяет отличить обновленную реализацию от исторического benchmark-среза.

21. Расширенная стратегия assurance: проверка утверждений, а не объёма тестов

Новый контур построен вокруг независимых oracle, метаморфных отношений и отрицательных controls. Число зелёных тестов отдельно не принимается за качество модели: проверяется, способен ли тест отличить корректный результат от известной семантической ошибки. Seed 2026101007, размеры серий, пороги и модель генерации сохранены в validation/advanced_protocol.json; текущий срез: 2026-10-10T22:51:24+0300.

Контрольные популяции, рынки и ответы создаются алгоритмически. Они подтверждают вычислительные контракты и поведение процедуры при заданных предпосылках, но не превращаются в результаты реальных кандидатов. Исторические workload и ranking benchmark не перезапускались: новый срез имеет отдельный протокол и не подменяет прежние измерения.



Слой	Независимый контроль	Критерий
GraphSAGE	Перестановки узлов/рёбер; переименование; исключённые атрибуты; disconnected component	Сохранение score по объекту, неизменность входа, конечность
Градиенты	Центральные разности независимо суммируемой scalar loss	Все 1105 координат; шаг 1e-5; допуск 2e-8
Назначение	Полный перебор физических людей и независимые eligibility/utility	Оптимальная цель, один человек/slot, неизменность hard constraints
Ролевая практика	Булева таблица четырёх gates; провал каждого обязательного критерия	Нельзя компенсировать отсутствие review, identity или практики
A/B	Положительная эквивалентность, boundary-null, явный сдвиг, planned looks	TOST, -budget, Wilson interval; без автоматического допуска
Ledger	Настоящие Rust/PostgreSQL HTTP races и rollback	Exactly-one freeze, causal order, sealed outcome, ownership
Чувствительность tests	Исполняемые семантические мутации	Намеренная ошибка должна приводить к отказу контракта

22. Фактические результаты независимых проверок

Каждая строка имеет самостоятельный знаменатель. 36 500 перебранных вариантов назначения — не 36 500 пользователей; 4000 probability/outcome pairs — не 4000 реальных наймов. Связанные perturbations одного графа не учитываются как независимые популяционные наблюдения. Численные допуски и свойства проверены отдельно от качества predictive labels.

Проверяемое свойство	Результат текущего среза	Область доказательства
Новые pytest checks	58 passed; 0 failures/errors	CPU + 9 live HTTP cases; повторные запуски не складываются
GNN metamorphic	400 graphs; max Δ=2.22e-16	400 identity/attribute и 400 disconnected controls
Градиенты	1105/1105; max |error|=1.34e-11	Один полный численный аудит на заданной topology/weights
Assignment	500 markets; 36500 exhaustive choices; error=0	8 резюме / 4 человека / 3 вакансии; 420 непустых optimum
Hard constraints	0 нарушений; 0 повторных назначений человека	Независимо проверены salary, role, grade, evidence
Ролевые gates	1200 cases; 0 ложных подтверждений	5 coding-role matrices × 3 grades; не human psychometrics
Proper scores	4000 pairs; 78875 AUC comparisons	Brier/LogLoss/AUC/ECE; max |error|=8.88e-16
Mutation sensitivity	13/13 killed; 0 survived	Заданные семантические ошибки, не whole-repo mutation coverage
Воспроизводимость	Два последовательных запуска: все deterministic results совпали	Сравнение включает все results; duration не объявляется детерминированным

23. Проверка A/B-процедуры на положительных, граничных и отрицательных controls

Welch-TOST проверен в четырёх заранее определённых условиях: истинный сдвиг 0, +0.2, −0.2 и +0.4; по 400 независимых Monte Carlo trials. В каждой группе 240 ответов Normal с SD=0.4; margin=0.2, =0.05. Результаты проверяют статистическую реализацию на описанном response process, а не эквивалентность ролевого банка на людях. Различие «не найдено различие» и «подтверждена заданная эквивалентность» сохранено.

На самой границе эквивалентности формальный null истинный: доли 5.00% и 4.50% — ожидаемые false equivalence acceptances, а не дефект, который следует скрыть. Wilson intervals отражают неопределённость конечного числа симуляций. При сдвиге 0.4 принято 0/400; верхняя граница 95% interval не равна нулю.

Истинный сдвиг	Принята эквивалентность	95% Wilson interval	Смысл
0.0	400/400 (100.00%)	99.05%–100.00%	Мощность при одинаковой шкале
0.2	20/400 (5.00%)	3.26%–7.60%	Boundary-null: ошибка I рода
-0.2	18/400 (4.50%)	2.87%–7.00%	Boundary-null: ошибка I рода
0.4	0/400 (0.00%)	0.00%–0.95%	Разделённые формы: negative control

24. Planned looks, uncertainty и безопасная трактовка сигналов

Для 400 независимых trials на boundary shift=0.2 проверены четыре вложенных просмотра одной пары групп: n=120/160/200/240. Применён declared alpha budget /4. Хотя бы одно ложное принятие эквивалентности получено в 14 trials: 3.50%; Wilson 95% 2.10%–5.79%. Четыре просмотра не складываются как четыре независимые выборки. Отдельный crafted control различает planned_looks=1 и planned_looks=20; удаление -budget обнаруживается мутационным тестом.

Beta posterior: 2000 prior-predictive simulations, p~Uniform(0,1), 80 Bernoulli наблюдений на trial. Покрытие nominal 90% credible interval = 89.75%; Wilson 95% 88.34%–91.00%. Это математическая согласованность prior-predictive модели, не доказательство полевой калибровки вероятности согласия.

Screening: по 1000 authored profiles в каждой группе. Clean timings имеют lognormal median 6500 ms / σ=0.9; rapid/constant control — 24 правильных ответа по 100 ms при expected_correct=0.25. Доли review: 0.00% и 100.00%; automatic sanctions = 0. Верхняя Wilson граница clean-review rate: 0.38%. Такие controls проверяют маршрутизацию на независимый разбор, а не подтверждают «100% обнаружение мошенничества».

25. Мутационный анализ: тесты обнаруживают намеренно нарушенную семантику

13 явно специфицированных mutants исполняются в отдельных Python namespace в памяти. Производственные исходники, веса и работающие процессы не меняются. Мутации охватывают denominator posterior, нижнюю Fréchet boundary, AND→OR hard gates, physical-person grouping, цену недопустимого assignment, all→any role conditions, minimum sample, planned alpha, silent activation, automatic accusation, Brier, AUC ties и нормализацию graph relations.

Текущий результат: 13/13 обнаружены. В первом диагностическом срезе один control не обнаруживал ошибку нижней Fréchet boundary: пары marginals были взаимодополняющими и не проверяли положительную нижнюю границу. Добавлена несимметричная контрольная серия; production метод не исправлялся, поскольку ошибочным был только специально внесённый mutant. Первый failed artifact сохранён; число archived failed attempts: 1. Это наблюдаемая обратная связь о качестве самих тестов, а не выбор только удобных запусков.

Killing rate относится исключительно к указанным 13 mutations. Он не объявляется coverage всей кодовой базы. Все типы исключений, выявившие нарушение, сохранены в rows; успешное выполнение немодифицированных controls является обязательным условием интерпретации.

26. Конкурентный и транзакционный контроль настоящего ledger

Девять новых live HTTP cases работают с настоящими Rust handlers и PostgreSQL на синтетических scoped fixtures. Восемь одновременных попыток freeze одной пары дают ровно один 200 и семь 409, с одной записью в БД. В шести отдельных races freeze конкурирует с первым намерением кандидата: допустим либо снимок раньше обоих решений, либо отказ 409 без записи. Клиент не задаёт server timestamp и вероятность.

После фиксации парного outcome 12 конкурентных смен намерений с четырьмя worker threads не переписывают первый outcome. Экспорт ограничен владельцем; кандидат не получает employer validation export. Недопустимый UPDATE вызывает PostgreSQL immutable trigger; транзакция

откатывается, данные совпадают с исходным снимком, а следующий authorized freeze другой стадии успешно выполняется. Проверка не исчерпывает все возможные schedules и не называется формальным доказательством distributed linearizability.

Все записи создаются в disposable identity/process scope и очищаются exact-ID fixture cleanup. Рабочая БД, prepared accounts, quota policy и сервисы не перезапускаются. Это bounded concurrency contract check, не нагрузочный benchmark и не замена длительного fault-injection испытания инфраструктуры.

27. Воспроизведение, evidence chain и первичные основания

Запуски: python -m scripts.advanced_assurance; python -m pytest tests/test_advanced_assurance.py tests/test_advanced_assurance_http.py --junitxml=validation/reports/current/advanced-assurance-tests.xml. Два последовательных CPU runs с одинаковыми SHA-256 источников дают равные results; latency/duration исключены из equality. Все прошлые CPU attempts сохраняются в advanced-assurance-attempts с именем SHA-256 самого artifact. Пороговые условия не изменялись по результатам симуляции.

Evidence: advanced-assurance.json — параметры, scores, intervals, mutants, версия Python и hashes; advanced-assurance-tests.xml — именованные pytest/HTTP cases; validation/advanced_protocol.json — контракт; scripts/advanced_assurance.py — независимые checks. Документ воспроизводит текущие artifacts и перед сборкой проверяет соответствие hashes исполняемым источникам.

Chen et al., 2018: Metamorphic Testing — A Review of Challenges and Opportunities — проверка результатов через отношения между преобразованными входами.

Papadakis et al., 2019: Mutation Testing Advances — An Analysis and Survey — оценивание adequacy тестов через выявление внесённых ошибок; DOI 10.1016/bs.adcom.2018.03.015.

Lakens, 2017: Equivalence Tests — A Practical Primer — TOST, заранее определённые bounds и различение equivalence от отсутствия significant difference. Источники проверены 10 октября 2026 года; они обосновывают методику, не являются независимой сертификацией Proofit.

28. Прицельная приемка проверенной категории

Проверены реальные HTTP handlers и persisted PostgreSQL states: self-report isolation, null/future/expired dates, cert binding, revocation, hidden/disputed, established finding/appeal, неудачный retest, согласия, idempotency/resume fencing и предложение без обязательной вакансии. Проверены защита будущих приватных резюме и фактическая weekly-проверка TypeScript при уже подтвержденных Python/SQL, включая отсутствие дублей. Disposable certificates в boundary suite служат предусловиями состояния; фактическое CAT issuance проверяется отдельным live qualification suite. Формулы EAP, typed GraphSAGE forward, Beta posterior и next-proof проверены независимыми численными оракулами. В этом срезе внешний opt-in GitHub probe пропущен, загрузка/OCR и LLM не запускались. Повторные suites не складываются с прежними измерениями.

Прицельная проверка	Сценариев	Результат
Rust/PG: границы категории и затронутые сценарии	70 passed	0 failures / 1 skipped

Прицельная проверка	Сценариев	Результат
CPU: затронутые методы и 26 численных оракулов	405 passed	0 failures / 0 skipped

29. Test–retest и стресс параметров заданий

Протокол assessment-robustness-1.0.0 зафиксирован до запуска: 360 пар, 720 попыток, пять ролей, independent response draws и параметрические A/B forms. Одинаковые латентные участники проверены при authored process и при b+0.35, log-normal a perturbation SD=0.2; параметры оценщика не подстраивались по результату. Все сценарии и boundary slices сохранены. Значения — контролируемая симуляция, не human calibration; автоматических изменений грейда и активации форм: 0.

При расстоянии ≥0.6 от границ agreement составляет 96.55% в authored process и 94.25% при mismatch. Полный agreement и near-boundary slices также опубликованы: уверенность не скрывает неопределенные пограничные случаи. Для paired accuracy применяется cluster bootstrap по латентному участнику; Wilson используется для долей независимых person-pairs. Точные строки и знаменатели — assessment-robustness.json.

Процесс ответов	Accuracy / retest	Accuracy при confidence≥0.85 / coverage
authored_process	87.50% / 0.8335	95.89% / 60.83%
parameter_mismatch	80.28% / 0.8182	91.86% / 61.39%