ПРУФ-ИТ / PROOFIT

Методология данных и паспорт набора

Происхождение, преобразования, границы разметки и воспроизводимость.

Редакция документа: 11 октября 2026. Архитектурные утверждения связаны с указанными модулями; числовые результаты — с протоколами измерений, их датами и областью применимости. Обновление документа не означает повторного проведения всех экспериментов.

Роли: специалист, работодатель, явно одобренный эксперт. Окончательное решение о найме, трактовка спорного evidence и разрешение на обработку данных не передаются автономному score.

1. Назначение набора

Набор используется для демонстрации профессиональных сценариев, проверки ranking policy и функционального coverage. Он не называется реестром реальных работников, репрезентативной выборкой рынка или completed hiring outcomes. Synthetic marker является частью постановки; контакты синтетических профилей пусты.

Численные модели и алгоритмы имеют отдельную методологию — 02_Methods.pdf. Этот документ отвечает на вопросы «откуда данные», «как преобразованы», «что означает label» и «какие выводы допускает выборка». Gold-метки не доступны runtime ranking handler.

2. Состав и свежая инвентаризация

Объект	Число / назначение	Проверка
Candidates	4040 synthetic profiles	Unique IDs; пустые contacts; source markers
Vacancies	494 scenarios	Salary bounds; source registry; IDs
Specializations	25 roles	Taxonomy/coverage, включая leadership
Private profiles	56	Privacy / отрицательный retrieval control
Candidate–vacancy labels	1995760	Все пары; label 0–3; foreign keys
Top-5 reference rows	2470	Отдельный deterministic reference; not runtime input
Source snapshots	170 vacancy references; 324 authored scenarios	research/source_evidence/source_registry.csv
Forecast holdout	3000 generator rows per task	Fresh seed; frozen model; no retune

3. Источники и преобразование

Source registry сохраняет vacancy ID, официальный портал, URL запроса, внешний ID, дату снимка и использованные/исключенные поля. 170 вакансий опираются на публичные snapshots «Работа России»; остальные 324 — сценарные расширения coverage. Из источника используются title, salary, freshness и experience; contact person, email, phone, точные адреса и полные тексты не перенесены в demo как реальные ПДн.

Имена компаний и кандидатов в scenario data являются демонстрационными; внешний vacancy title не делает профиль реальным работодателем. Date snapshot не объявляется актуальной вакансией сегодня. В реальной обработке PDF field provenance сохраняет page/quote/method, reviewed fields и предупреждения; подтверждение пользовательского ввода отделено от модельного extraction.

4. Разметка и контрольная политика

Relevance 0–3 задается профессиональными и условными правилами сопоставления роли, уровня, набора навыков и оплаты. Labels являются authored scenario oracle, не итогом независимого голосования реальных recruiters. Exact top-5 reference кодирует конкретный порядок; nDCG оценивает качество градаций независимо от полного совпадения IDs.

Candidate-side recommendation использует transposed pairs; directional ожидания и роль fallback различаются, поэтому отдельные показатели salary compatibility не скрыты. Синтетические поля assessment_attempts и employment scenarios служат fixtures состояния; они не объявляются выполненными реальными тестами пользователей. Новая квалификация реализована CAT, а исторический dataset question_bank не превращается в весь текущий runtime bank.

5. Integrity и разделение train/test

Свежий аудит проверяет IDs, salary consistency, synthetic markers, отсутствие contacts, все gold foreign keys, distribution и top-5 references. Результат: 1995760 valid pairs; распределение labels: {'2': 15418, '1': 82897, '0': 1872820, '3': 24625}. SHA-256 источников приведены ниже и в machine artifact.

Frozen CatBoost обучен на synthetic generator постановке; свежий holdout uses seed 20261009 и не участвует в retuning. Значение R^2 говорит о воспроизведении данного генеративного процесса, не о точности прогнозирования наблюдаемого времени трудоустройства. CAT Monte Carlo также является отдельным authored response process, не человеческими ответы из данного набора.

6. Data governance

Производственная загрузка требует разрешенного источника и прав обработки. Минимизация отделяет профессиональную информацию от контактов; public search требует processing/publication consent; portable proof не содержит прямых identifiers. External source URL, timestamp и статус никогда не заменяются выдуманной записью для заполнения красивого интерфейса.

Изменение taxonomy, источника, разметки или генератора требует нового dataset version/hash и повторной проверки. Не исправлять gold под текущую выдачу после просмотра ошибок: discrepancy сохраняется в report и объясняется policy. Разработка новых role forms должна добавлять executable или независимый expert oracle, а не считать generated answer key проверкой самого себя.

7. Ограничения переноса и корректное применение

Dataset показывает completeness сценариев и correctness реализации по объявленной policy. Для внешней utility нужны реальные экспертные оценки релевантности, authorization на данные и longitudinal outcomes. Private controls и synthetic fixtures усиливают повторяемую проверку, но не заменяют экономическую или психометрическую репрезентативность.

Допустимые выводы: API соблюдает заданные constraints; текущая выдача согласуется с authored gold с указанными метриками; вариативные tasks имеют проверенный ключ; private entries исключены. Недопустимый вывод: любой реальный работодатель или кандидат получит точно такое же качество, сроки или доход.

8. Контрольные суммы исходных данных

Файл	SHA-256	Назначение
applications.csv	`5097d47397af341df5f309b7ebb257955ff3787bf52dc66a6d719e9fad8055b5`	Текущий source artifact; полный аудит data-audit.json
assessment_attempts.csv	`b7e245e046a95299f88d83f0467ca73fd9cd348514bc07c11cedd460e51d3230`	Текущий source artifact; полный аудит data-audit.json
assessment_blueprints.csv	`2f68a4dee629da3505aaabb57a0baa728feb1b16f3d3446b00528650148c43a9`	Текущий source artifact; полный аудит data-audit.json
candidates.csv	`3dbcd85f33961a8323cbf04bd3b4a8f8512d8e441def4ba16f18e5a7ed2a5252`	Текущий source artifact; полный аудит data-audit.json
coverage_by_specialization.csv	`83335646c1d6d6f80f5369374204253c8811f59a2c792fa8853f13e5ddd8f1d8`	Текущий source artifact; полный аудит data-audit.json
dialogue_cases.csv	`cd9999ed8a4156003aea2e68314fd458c93e345fb615e644268093e3ad16ecb3`	Текущий source artifact; полный аудит data-audit.json
employers.csv	`0f96dfd41a6ac6a641ea723ce7ad09318127c9853b33136bba062c0f1c1554f8`	Текущий source artifact; полный аудит data-audit.json
expected_top5.csv	`ac483f5831e8f7d92ca8948d1da88284bf3d2d7b428c1c3e2e98f65025688b4d`	Текущий source artifact; полный аудит data-audit.json
fsp_achievements.csv	`f323cf8c861ccbcabbc1c10bc0a8b58ef694d7656fbf1b289234dc51a3d92ad0`	Текущий source artifact; полный аудит data-audit.json
interview_rubrics.json	`8a7d95ca4171b8b052e700ad4fb2e5c019804889eeddd192110a0e1676a88320`	Текущий source artifact; полный аудит data-audit.json
invitations.csv	`1db3446d29bd272dd95d2fc5cb319ff27b54d2c5742a4225695142712d947237`	Текущий source artifact; полный аудит data-audit.json
micro_tasks.csv	`a542e4b2700ed3d3adbb49326cebc5e3c7c9542ad29f5a279b7bd2c092b6e35d`	Текущий source artifact; полный аудит data-audit.json
question_bank.json	`51da286f14f3288f75e57ce34d1c5b6b4d6a16883233a37dd790af64157259ed`	Текущий source artifact; полный аудит data-audit.json
relevance_labels.csv	`456b4683b7806d683874f1247d68da513e2d369be787ec1f492b7f06a8454a8c`	Текущий source artifact; полный аудит data-audit.json
relevance_labels.csv.gz	`6d4ec16779569a668b64a28619fb73b9c9d688632ea3df09768164c8a8fcae56`	Текущий source artifact; полный аудит data-audit.json
salary_calibration.csv	`15fe7369978ce4bfa83f079854e41490eff7d80bfb1cadac0e8002a0fa1dd47b`	Текущий source artifact; полный аудит data-audit.json
taxonomy.json	`3de047f50cfe5a1863264ca8b982bef4de3958ad85faf08c7b9c3e9c01df911d`	Текущий source artifact; полный аудит data-audit.json
vacancies.csv	`ef17b4434e9f9aff3b826de8837401f01835d9f43d397bea9fa2a30b18a60cff`	Текущий source artifact; полный аудит data-audit.json

9. Новые наблюдения и контрольные данные

GitHub snapshot содержит origin, head SHA, digest и ограниченность выборки. Парные намерения разделяют стадии vacancy/offer и сохраняют цензуру. Market inventory сохраняет synthetic counts и область role/grade/industry. GNN teacher, Monte Carlo и TOST численные controls не называются независимыми человеческими labels. Генерация переводов использует локальную модель, но статистические проверки методов не вызывают LLM.